

RELATÓRIO TÉCNICO DOS PROCESSOS DE IDEACÃO E PROTOTIPAÇÃO DA SOLUÇÃO BESIDE.ME

Fernando Neri, Ivanildo Pontual Neto, Lucas Diego Barbosa, Márcio Juchneski¹

¹Universidade Federal Fluminense (UFF) – Instituto de Computação (IC)

Programa de Pós-Graduação em Computação (PGC)

Disciplina: Computação Ubíqua.

Niterói, RJ – Brasil – 01 de Dezembro de 2019.

{ffneri,ivanildopontualneto,barbosa_lucas,marciojuchneski}@id.uff.br

1. Introdução

Como componente avaliativo da disciplina de Computação Ubíqua, nesse relatório são apresentadas as etapas de todo o processo de desenvolvimento do protótipo da solução **beside.me**, desde a aplicação de técnicas de *design thinking*, passando pelos procedimentos de revisão sistemática de literatura e por fim no processamento e classificação de *dataset*.

2. Técnicas Empregadas

Neste segmento são apresentadas algumas técnicas empregadas na condução do estudo e posterior desenvolvimento da solução.

2.1. Design Thinking

Em um primeiro momento, para que fosse possível definir um escopo de aplicação a ser desenvolvida foi realizado um workshop que utilizou a técnica de *brainstorming*, sob orientação em sala de aula, mas se estendeu posteriormente para que as idéias geradas fossem selecionadas e refinadas.

Nesse sentido, o *brainstorming* faz parte do processo de *Design Thinking* como uma abordagem chamada *Human Centered Design* que tem como base técnicas de imersão no ambiente para obter melhores *insights* e dessa forma obter ferramental com maior carga de experiência. Isso permite uma integração com maior fidelidade ao escopo do projeto. Um designer, com essas abordagens em mãos, consegue integrar as necessidades das pessoas, as possibilidades da tecnologia e os requisitos para propor de soluções criativas.

Baseado nisso e nas discussões realizadas, surgiu a ideia de uma solução pessoal preventiva que infere possíveis comportamentos atípicos em pessoas com transtornos mentais que estejam sob tratamento. Partimos da perspectiva de que pessoas portadoras de transtornos mentais e dependentes químicos estão vulneráveis e suscetíveis a falta de assistência contínua durante seu período de tratamento. Assim podem ocorrer crises, surtos e convulsões potencialmente não assistidas pela equipe médica responsável. Assim, o propósito do **beside.me** é ser um aliado ao paciente sob tratamento (seja temporário ou contínuo), por meio de sensores e *feedbacks* do usuário, inferir possíveis mudanças de comportamento não assistidas.

Como cenário para desenvolvimento dessa solução, temos a reforma psiquiátrica de 2001 que mudou o paradigma de atendimento e atenção a pessoas portadoras de transtornos mentais e de dependência química. Buscou-se com essa reforma, instituir um

cuidado humanizado para essas pessoas com transtornos mentais e usuários de álcool e outras drogas.

Os Centros de Atenção Psicossocial (CAPS), as Unidades de Acolhimentos (UA) e as Residências Terapêuticas, geralmente configuram o cenário mais comum de atendimento e acolhimento de pessoas com transtornos mentais graves e persistentes e também com necessidades decorrentes do uso de *crack*, álcool e outras drogas.

Os Centros têm a função do primeiro atendimento, tratamento e triagem, enquanto as Unidades de Atendimento e Residências Terapêuticas o acolhimento, internação e correto tratamento de casos mais graves (amparados pela lei) e sua reinserção na sociedade. A maioria dos pacientes em tratamento, ou seja, os não internados, tenta ter sua vida mais próxima possível do "normal". Contudo, os problemas podem potencialmente aparecer justamente na falta de assistência em momentos oportunos, seja profissional ou familiar.

É nesse momento que verifica-se que a tecnologia pode auxiliar no tratamento desses perfis de pacientes, potencialmente desassistidos ao longo de sua recuperação, através de uma espécie de assistente pessoal inteligente e personalizada, que tenta entender e se antecipar às mudanças de comportamento observadas.

Partindo dessa premissa (e dando sequência a própria proposta do *design thinking*) foram criadas três *personas* – podendo ser compreendidas como representações fictícias de usuários ideais de um determinado serviço. No caso do *beside.me*, foram descritos um profissional de saúde (médico) e dois pacientes psiquiátricos.

Outra etapa foi a criação dos *points of view* (pontos de vista) que permitem, dada a definição prévia, junto às *personas* uma visão sistêmica do problema a ser solucionado. Tal ferramenta permitiu a percepção de alguns *insights*, como:

- O PROFISSIONAL DE SAÚDE precisa de MAIS CONHECIMENTO sobre os hábitos e comportamentos do paciente em suas rotinas diárias para DIAGNOSTICAR de forma mais assertiva e INTERFERIR em potenciais adversidades enfrentadas pelo paciente;
- O PACIENTE precisa PERCEBER a evolução do seu quadro clínico e se SENTIR assistido continuamente, para PREVENIR possíveis crises de ansiedade/surtos podendo até tentar descontinuar o tratamento (recaídas).

Assim, o impacto social tido como objetivo da solução é o de auxiliar na qualidade de vida de pessoas com algum tipo de transtorno psicológico, propondo um meio de fornecer relatórios sobre as variações do estado emocional do paciente ao profissional da saúde e permitindo também a possibilidade do usuário saber sobre seu estado emocional.

Complementar a isso, têm-se como principais diferenciais da solução além da captação de dados para acompanhamento por profissionais de saúde, a possibilidade de fazer acompanhamento do tratamento tentando prever uma possível crise e o *feedback* gerado ao usuário sobre sua situação emocional.

Dado o cenário, para todo o processo de *design* da ideia proposta, o *beside.me*, fizemos o uso de três etapas: inspiração, ideação e prototipação.

2.1.1. Inspiração

Para criar algo que seja valioso ou que solucione algum problema de uma população, as soluções precisam que os envolvidos tenham um entendimento profundo das necessidades daquele público-alvo. Nessa fase de imersão, buscou-se entender quais as suas necessidades a partir de uma técnica chamada pesquisa *desk*, que tem como característica a coleta do maior número de informações possível a respeito do mundo estudado. Essa técnica pode nos dar inspirações para solucionar de forma criativa as necessidades e também o conhecimento necessário sobre a área em que se busca interagir.

Dessa forma, a partir do que foi apresentado em sala, decidiu-se seguir para a tentativa de encontrar algo relacionado ao lado emocional de pessoas que possam ter ou já tiveram algum episódio de depressão durante suas vidas e/ou estão em acompanhamento por uma unidade de saúde CAPS.

Assim, nas 2 semanas seguintes, cada membro do grupo fez uma pesquisa sobre o funcionamento das unidades de saúde CAPS e seus tipos de pacientes e sobre possíveis tipos e causas da depressão com seus sintomas físicos e emocionais.

Nesse prazo, entrou-se em contato com o coordenador da unidade CAPS do município de Niterói e foi realizada uma reunião informal para tentar compreender as necessidades da unidade de saúde. Devido à agenda do coordenador, a entrevista não pode ser realizada pessoalmente e acabou sendo feita por telefone. Junto com a entrevista, foi somado também, a experiência de um dos participantes do projeto por ter trabalhado em uma unidades de saúde física e mental por 4 anos e que também teve um parente de 1º grau internado em uma unidade do CAPS.

Ao final do prazo, fez-se um processo chamado divergência e convergência, onde todos apresentaram os resultados de suas pesquisas (divergência) e em seguida decidiu-se qual seria o ponto a atacar (convergência). Essa reunião teve duração de 6 horas.

2.1.2. Ideação

A fase de ideação é responsável por transformar a pesquisa em algo significativo que poderão dar *insights* para a fundação da proposta.

Inicialmente foi agrupado todo o conhecimento adquirido e mesclou-se as ideias que faziam mais sentido às pessoas que buscava-se atingir. Assim, isso ajudaria a identificar chaves que permitiriam definir quais oportunidades seriam as mais viáveis atacar. Dentre o mundo possível de variáveis encontradas pela equipe, as mais discutidas foram a viabilidade do produto/serviço que poderíamos desenvolver, a facilidade de uso, preço, quais sensores utilizar e a condição física e emocional da pessoa que seria usuária.

A condição física e emocional foi um ponto chave, pois poderiam existir usuários que estivessem em uma crise que acarretariam danos ao dispositivo e havia o objetivo de que o produto entregue fosse o menos invasivo possível. Tendo isso em mente, surgiu a ideia de que poderia se utilizar de equipamentos vestíveis que possuísem *Bluetooth* ou *Wi-Fi* disponíveis e também que pudessem coletar dados do usuário.

Para a coleta de dados do usuário, foram encontradas, com a ajuda da revisão sis-

temática, possíveis soluções que poderiam ser implementadas para identificar o possível sentimento do usuário. Assim, conseguiu-se definir qual tecnologia utilizar e quais dados coletar do usuário.

Foi decidido então que seria utilizado um *smartwatch* e um *smartphone* e os dados seriam coletados de acelerômetros e sensores de pulsação do usuário.

2.1.3. Revisão Sistemática da Literatura

Como parte da proposta de busca por uma solução efetivamente inovadora, foi realizada uma revisão sistemática de literatura (RSL), cujo objetivo foi o de reunir o estado da arte relacionado ao tema de surtos/crises de ansiedade em pacientes com transtornos psicológicos/dependência química.

Compondo ainda o planejamento desse levantamento, foi definida a população de pacientes com transtornos psicológicos, as *keywords* (palavras-chave) de pesquisa – *activity recognition*, *mental health*, *anxiety*, *psychological disorder* e *sensor(s)* – e a respectiva *string* de busca:

```
(\activities of daily living" OR \activity recognition")  
AND (\mental health" OR \psychological disorder" OR \anxiety"  
OR \stress" OR \behavior") AND (\ubiquity" OR \pervasive") AND  
(\sensor" OR \sensors").
```

Posto isso foram também definidas as "questões de pesquisa" para avaliação e seleção de estudos relacionados, sendo elas as seguintes:

- Existem modelos que descrevem comportamentos anormais, como crises e transtornos de ansiedade humana através de dados de sensores vestíveis?
- Quais dados podem ser extraídos do usuário para o reconhecimento do transtorno psiquiátrico?
- Quais sensores foram utilizados?
- Quais algoritmos/classificadores foram utilizados?
- Qual o país de pesquisa do artigo?

Complementar às questões foram desenvolvidos os critérios de exclusão e inclusão para a seleção de estudos, sendo eles:

- Ano de publicação anterior a 2015;
- Estudos não publicados em inglês;
- Estudos que não tratam do tema pesquisado;
- Literatura cinza;
- Resumos de Congressos e Conferências;
- Short papers.

Já os critérios de inclusão:

- Estudos publicados online;
- Estudos que abrangem a utilização de sensores vestíveis para detectar transtornos/crises em pacientes;

- Estudos que abrangem a utilização de outras informações de contexto para detectar transtornos/crises em pacientes.

Como resultado dessa seleção de dados para busca e utilizando a *string* pré-definida, foram encontrados um total de 222 estudos que após sucessivos processos de refinamento – três etapas de aplicação dos critérios de inclusão/exclusão, que delimitaram a quantidade de estudos respectivamente a 39, depois reduzindo para 25 e por fim a 9 artigos: [1][2] [3] [4] [5] [6] [7] [8] [9].

Source	Imported Studies
ACM Digital Library	38
El Compendex	25
IEEE Digital Library	94
Science@Direct	14
Scopus	51

Figura 1. Total de Estudos Selecionados por Base.




Figura 2. Gráfico de Estudos Selecionados por Base.

2.1.4. Prototipação

Esta etapa do processo permitiu colocar as fases de imersão e ideação em prática. Assim, deu-se início ao processo de busca por *datasets* que contivessem os dados necessários para a aplicação. Esta etapa foi a que obteve-se maior frustração, pois houve extrema dificuldade em encontrar um *dataset* que contivesse o mínimo dos dados de sensores que efetivamente seriam necessários para a aplicação a ser desenvolvida.

2.2. Depresjon: A Motor Activity Database of Depression Episodes in Unipolar and Bipolar Patients

De qualquer forma, para inferência de possíveis anomalias no comportamento do usuário, foi selecionado então o *dataset* **Depresjon** [10], que trata de atividades motoras relacionadas à depressão.

O *dataset* em si contém registros de atividades motoras de 23 pacientes em quadro depressivo e 32 considerados saudáveis, onde para cada usuário, foram gerados dados de sensores durante vários dias de medições contínuas e alguns dados demográficos. Já a severidade do estado depressivo foi rotulado usando classificações desenvolvidas por especialistas médicos através do *Montgomery-Asberg Depression Rating Scale (MADRS)* (Escala de Classificação para Depressão de Montgomery-Asberg).

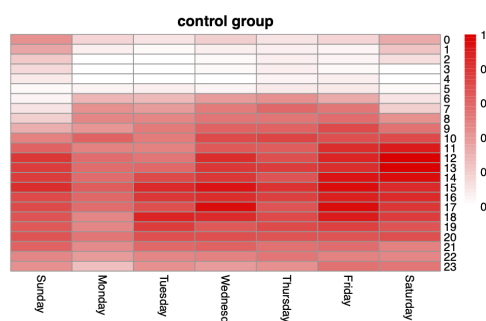


Figura 3. *Heatmap* dos pacientes não depressivos - *control*.




Figura 4. *Heatmap* dos pacientes depressivos - *condition*.

Com o *dataset* em mãos, em um primeiro momento cogitou-se utilizar a ferramenta Weka (*Waikato Environment for Knowledge Analysis* – Ambiente Waikato para Análise de Conhecimento), um software de código aberto que dispõe de uma coleção de algoritmos de aprendizado de máquina para a realização de tarefas de mineração de dados, contendo ferramentas para pré-processamento de dados, classificação, regressão, clusterização, além de extração de regras de associação e visualização, possuindo também suporte a *deep learning* (aprendizagem profunda).

Contudo, por uma abordagem mais prática e pela própria natureza do *dataset*, optou-se pelo desenvolvimento de um classificador em *Python*, descartando assim a utilização do Weka.

2.3. Infraestrutura

Em relação a infraestrutura, originalmente seguindo a proposta de execução do projeto, a aplicação utilizaria a plataforma ContextNet como uma espécie de *middleware* – [11] camada introduzida entre aplicações e sistemas operacionais (OS) que permite encapsular, modularizar e simplificar o acesso a recursos distribuídos e heterogêneos, expondo serviços (por exemplo, bases de dados e sistemas de arquivos) de maneira que sejam independentes da própria aplicação e do sistema operacional.

E, como base do ContextNet, consequentemente definiu-se a utilização do OpenSplice – uma avançada, completa e largamente usada (tanto comercialmente quanto de forma *open source*) implementação do padrão de serviço de distribuição de dados para grupo de gerenciamento de objetos (OMG DDS), permitindo que esses dados sejam compartilhados e integrados em um larga base de sistemas operacionais e plataformas.

Porém o OpenSplice, que é um requisito para o correto funcionamento do Contextnet não é de uso gratuito e tem sua janela de testes para apenas 30 dias, o que tornou inviável a utilização devido a dificuldade encontrada por todos os membros do grupo para que o mesmo tivesse seu funcionamento da forma adequada. O período de avaliação do OpenSplice terminou antes mesmo que fosse possível entrar na etapa de prototipação, inviabilizando a implementação da solução.

Como tentativa de solucionar esse problema com o OpenSplice, tentou-se utilizar uma ferramenta similar baseada em *Python*, porém seu uso requer uma série de pré-configurações também não tendo sido encontrados tutoriais para auxílio nessa questão. Dessa forma, foi necessário suprimir a utilização de um *middleware*.

2.4. Avaliação do Conjunto de Dados

Conforme já apresentado na subseção 2.2, foi utilizada como base um conjunto de dados referentes a atividades de dois grupos de pessoas, o primeiro de pacientes diagnosticados como depressivos e o outro de pessoas não diagnosticadas. Para manipular o *dataset* e construir o algoritmo de classificação, optou-se pela linguagem de programação *Python*, dada a facilidade para manipulação de dados e implementação de classificadores. Assim, foram utilizadas as bibliotecas:

- *numpy*
- *pandas*
- *keras*
- *scikit-learn*

2.4.1. Pré-Processamento

Analisando o *dataset* e conforme está descrito no artigo, este conjunto de dados já possui uma certa discretização, ela se resume a transformação de dados contínuos em intervalos de 1 minuto. Dessa forma, a cada minuto (representado por 1 linha no *dataset* de cada pessoa) somam-se os dados de movimentação de realizados ao longo desse tempo, como se fosse um *score* variando de 0 a $+\infty$. A atividade de pré-processamento se resumiu nas seguintes atividades:

- Leitura dos arquivos separados por pessoa (CSVs);

- Limpeza dos dados, utilizando os dados da coluna atividade;
- Truncamento dos dados, segunda discretização temporal dos dados;
- Normalização dos dados;
- Junção dos dados de pacientes depressivos e não depressivos.

Nesta fase, foram avaliados diferentes tamanhos de truncamento dos dados, dado que estes influenciavam no resultado do classificador. Observou-se que os seguintes intervalos: 60, 120, 180, 360, 720 e 1440 construíam bons resultados no treinamento, mas divergiam nos resultados de teste. Assim, percebeu-se que quanto menor o intervalo de tempo, melhor a classificação no treinamento, contudo, produziam uma condição de *overfitting* (superajuste) no *dataset*. Por isso, ao longo de vários testes, foi escolhida como subdivisão dos dados temporais o valor de 180 (180 min - 3 horas), que produz uma boa generalização, mantendo uma acurácia próxima de 72%, que foram os melhores resultados obtidos pelo artigo publicado.

2.4.2. Classificação

Para a tarefa de classificação do conjunto de dados, utilizou-se como técnica o conceito de Redes Neurais Artificiais com Aprendizado Profundo. A primeira fase consistiu em testar quais parâmetros melhoravam os resultados do classificador tanto para o treino, quanto para o teste. Para isso, foi usado o *GridsearchCV* do *scikit-learn*, que é um método de pesquisa exaustiva sobre os valores de parâmetros especificados para um preditor. Dele obtém-se valores de melhores parâmetros para construção da Rede, como por exemplo, o estimador "Adam" (de *Adaptive Moment Estimation* que se desempenhou melhor que o outro testado, o RMSprop. No caso dos parâmetros *batch_size* e *epoch*, utilizamos diversos valores (10, 16, 32 e 64 para *batch* e 25, 50, 100, 150 para *epoch*). Assim, também foram escolhidos os seguintes parâmetros para construção do modelo:

- *estimator* = Adam;
- *epoch* = 50;
- *batch_size* = 32;
- *cross-validation* = 10;

Além disso, para a construção das camadas da rede, usou-se como parâmetros de primeira e segunda camadas a função de ativação ReLU (*Rectified Linear Unit*) que é sempre uma escolha recomendada para ser utilizada nas camadas iniciais e intermediárias (*hidden-layers*) na construção da rede. Já para a camada de saída, utilizou-se algumas funções de ativação como *softmax* e *sigmoid* e optou-se por esta última devido ao seu melhor desempenho para este conjunto de dados em específico.

2.4.3. Resultados Obtidos

Após uma série de treinamentos e testes com o conjunto de dados estudado, obtiveram-se os seguintes resultados representados abaixo. Para o treinamento da Rede, neste conjunto de dados, dividindo obviamente em conjuntos de dados treino e teste (disjuntos) conseguiu-se uma **média** de acurácia de 71% das 10 validações cruzadas (min: 65,28% - max: 74,88%) nos parâmetros acima mencionados, com uma variância de aprox. 2,76%.

Com relação ao subconjunto de teste, obteve-se uma acurácia de 72,68%, com o $Precision=0,74$ e $Recall=0,89$, valores muito próximos dos melhores resultados obtidos pelo artigo publicado, demonstrando um potencial para futuras publicações, testando-se com outras técnicas de classificação.

3. Considerações Finais

Como um primeiro estudo e protótipo a ser projetado percebeu-se que o desenvolvimento de tal solução é possível, mas ainda depende de um determinado período de maturação, tanto para o desenvolvimento de predições mais bem estabelecidas quanto de uma infraestrutura que garanta real ubiquidade.

Contudo, o desenvolvimento baseado em *design thinking* provou-se extremamente relevante em todo o processo criativo aliado também a revisão sistemática da literatura, que garantiu uma visão crítica quanto à real contribuição do que buscou-se como solução e trouxe uma série de outras perspectivas quanto a percepção que a equipe possuía em relação ao problema estudado.

Referências

- [1] K. Van Laerhoven, M. Wenzel, A. Geelen, C. Hübel, M. Wolters, A. Hebestreit, L. F. Andersen, P. van't Veer, and T. Kubiak, "Experiences from a wearable-mobile acquisition system for ambulatory assessment of diet and activity," in *Proceedings of the 4th International Workshop on Sensor-based Activity Recognition and Interaction*, iWOAR '17, (New York, NY, USA), pp. 3:1–3:8, ACM, 2017.
- [2] X. Gao, H. Luo, Q. Wang, F. Zhao, L. Ye, and Y. Zhang, "A human activity recognition algorithm based on stacking denoising autoencoder and lightgbm," *Sensors*, vol. 19, no. 4, 2019.
- [3] M. Shoaib, S. Bosch, O. Incel, H. Scholten, and P. Havinga, "Complex human activity recognition using smartphone and wrist-worn motion sensors," *Sensors*, vol. 16, p. 426, Mar 2016.
- [4] S. Yu and L. Qin, "Human activity recognition with smartphone inertial sensors using bidir-lstm networks," in *2018 3rd International Conference on Mechanical, Control and Computer Engineering (ICMCCE)*, pp. 219–224, Sep. 2018.
- [5] S. A. Khowaja, A. G. Prabono, F. Setiawan, B. N. Yahya, and S.-L. Lee, "Contextual activity based healthcare internet of things, services, and people (hiotsp): An architectural framework for healthcare monitoring using wearable sensors," *Computer Networks*, vol. 145, pp. 190 – 206, 2018.
- [6] J. Lu, J. Wang, X. Zheng, C. Karmakar, and S. Rajasegarar, "Detection of smoking events from confounding activities of daily living," in *Proceedings of the Australasian Computer Science Week Multiconference*, ACSW 2019, (New York, NY, USA), pp. 39:1–39:9, ACM, 2019.
- [7] M. A. U. Alam, N. Roy, S. Holmes, A. Gangopadhyay, and E. Galik, "Automated functional and behavioral health assessment of older adults with dementia," in *2016 IEEE First International Conference on Connected Health: Applications, Systems and Engineering Technologies (CHASE)*, pp. 140–149, June 2016.
- [8] C. Dobbins and S. Fairclough, "Signal processing of multimodal mobile lifelogging data towards detecting stress in real-world driving," *IEEE Transactions on Mobile Computing*, vol. 18, pp. 632–644, March 2019.
- [9] G. Valenza, M. Nardelli, A. Lanata, C. Gentili, G. Bertschy, and E. P. Scilingo, "Predicting mood changes in bipolar disorder through heartbeat nonlinear dynamics: A preliminary study," in *2015 Computing in Cardiology Conference (CinC)*, pp. 801–804, Sep. 2015.
- [10] E. Garcia-Ceja, M. Riegler, P. Jakobsen, J. Tørresen, T. Nordgreen, K. J. Oedegaard, and O. B. Fasmer, "Depresjon: A motor activity database of depression episodes in unipolar and bipolar patients," in *Proceedings of the 9th ACM Multimedia Systems Conference*, MMSys '18, (New York, NY, USA), pp. 472–477, ACM, 2018.
- [11] S. Poslad, *Ubiquitous Computing: Smart Devices, Environments and Interactions*. Wiley Publishing, 1st ed., 2009.